

Data Cleaning (Preprocessing Data)

1. Xóa cột không sử dụng

- Xóa cột meta_title (100% giá trị rỗng, không có giá trị phân tích).
- Xóa short_description (không phục vụ Business Question/KPI nào).
- Xóa quantity_sold_text không cần thiết cho phân tích.

2. Loại bỏ trùng lặp (Deduplication)

- Xóa các bản ghi product trùng lặp dựa trên id.
- Xóa các bản ghi review trùng lặp dựa trên comment_id.

3. Chuẩn hóa văn bản

- Áp dụng cho 3 cột: brand_name, seller_name, category_name.
- Loại bỏ khoảng trắng thừa ở đầu/cuối chuỗi.
- Chuẩn hóa lại giá trị thiếu: do bước ép kiểu chuỗi (astype(str)) vô tình biến giá trị rỗng (NaN) thành chuỗi "nan", bước này chuyển ngược lại đúng thành NaN chuẩn — tránh để "nan" bị hiểu nhầm là 1 tên brand/seller hợp lệ khi group by.

4. Xử lý giá trị thiếu theo ý nghĩa nghiệp vụ

- **quantity_sold_value** thiếu (~42.5% số dòng) không có nghĩa là "đã bán 0 đơn vị", mà là "chưa ghi nhận giao dịch nào". Nếu điền 0 trực tiếp sẽ xóa mất sự khác biệt này. -> Trước khi tạo cờ, đối chiếu thêm với all_time_quantity_sold: phát hiện 4 dòng có giá trị ở cột này nhưng lại thiếu ở quantity_sold_value -> dùng để lấp các dòng đó trước (tránh mất dữ liệu), rồi xóa all_time_quantity_sold vì đã dư thừa. -> Tạo cờ has_sold (True: đã ghi nhận doanh số, False: chưa) và cột quantity_sold_value_filled (điền 0 cho dòng thiếu, phục vụ groupby/sum thuận tiện). Cột gốc quantity_sold_value vẫn giữ nguyên, không xóa - vì cần phân biệt đúng "chưa bán" khi lọc theo has_sold.
- **8 bản ghi thiếu seller_id/category_id**, có thể là sản phẩm đã ngừng bán hoặc bị gỡ khỏi hệ thống tại thời điểm crawl. -> Tạo cờ possibly_delisted để đánh dấu, xem xét thủ công thay vì xóa ngay.

5. Kiểm tra logic Giá & Giảm giá (Regression check)

- Dùng original_price làm giá tham chiếu (đáng tin hơn list_price).

- Tự tính lại `discount_rate_calc` từ giá, so sánh với `discount_rate` lấy từ API để phát hiện sai lệch bất thường.
- **Phát hiện & sửa lỗi:** ngưỡng cảnh báo ban đầu đặt > 5 điểm %, nhưng `discount_rate` từ API vốn đã làm tròn về số nguyên nên sai số làm tròn tối đa chỉ ~0.5 điểm % -> ngưỡng cũ quá lỏng, không bao giờ bắt được sai lệch thật. Đã điều chỉnh ngưỡng còn 1.0 điểm % để việc kiểm tra có ý nghĩa thực sự.
- Chạy lại 2 điều kiện kiểm tra (assert): không có `price <= 0`, không có `original_price < price` sau khi cleaning - đảm bảo không phá vỡ các kết quả đã audit trước đó.
- Sau khi sửa ngưỡng, phát hiện đúng **2 bất thường thật** (id 234 — Nồi cơm điện Tiger JNP-1000, id 479 — Bếp Từ Đơn Sunhouse SHD6803): cả 2 sản phẩm có `price < original_price` rõ ràng (lệch tới 15.29 điểm %), nhưng field `discount_rate` do Tiki hiển thị lại là 0 — đây là lỗi dữ liệu nguồn từ phía Tiki, không phải lỗi cleaning. `discount_rate_calc` đáng tin hơn cho 2 dòng này. **Giữ nguyên cột `discount_rate_mismatch`**, không xóa — cột đang hoạt động đúng chức năng cảnh báo.

6. Tạo phân khúc phục vụ phân tích

- `price_bucket`: chia theo 5 khoảng giá (<100k, 100-300k, 300-700k, 700k-1.5tr, >1.5tr).
- `discount_bucket`: chia theo 6 khoảng mức giảm giá (0% đến >50%).
- `subcategory_proxy`: gán nhãn danh mục con dựa trên từ khóa trong `product_name` (heuristic, không phải taxonomy chính thức từ Tiki, vì field `category_name` gốc chỉ có 1 giá trị hằng số "Điện Gia Dụng"). Logic này được đặt tại đây (thay vì ở notebook EDA như bản đầu) để chỉ tồn tại **1 nguồn tính toán duy nhất**, tránh 2 nơi cùng chứa logic phân loại dễ lệch nhau khi chỉnh sửa sau này.

7. Đối chiếu số lượng review

- So sánh `review_count` (field tính trên trang sản phẩm) với `crawled_review_count` (số review crawl thực tế).
- Phát hiện một số sản phẩm lệch lớn (chênh hơn 3 lần) -> ưu tiên tin `crawled_review_count` vì đây là số đo thực tế tại thời điểm crawl, không phải field tính có thể lỗi thời.

8. Xử lý nội dung review bị thiếu

- Một số review chỉ có rating mà không có content - đây là hành vi hợp lệ (khách chỉ chấm sao, không viết nhận xét), không phải lỗi crawl -> không xóa các dòng này.
- Chuẩn hóa chuỗi rỗng ("") thành NaN, tạo cờ `has_content` để các bước phân tích văn bản (word frequency, keyword tagging) sau này loại các dòng không có nội dung ra khỏi phạm vi phân tích.

9. Xóa cột dư thừa (sau khi đã kiểm chứng bằng code)

- `short_description`: không phục vụ Business Question/KPI nào.
- `quantity_sold_text`: đã hoàn thành nhiệm vụ đối chiếu missingness ở mục 4.

Xóa sau khi kiểm chứng bằng code (audit mở rộng):

- **`list_price`**: 2/2001 dòng lệch so với **`original_price`** (id 234, 479) - điều tra cho thấy ở cả 2 dòng `list_price` chỉ trùng lặp `price` hiện tại, không mang thêm thông tin tham chiếu nào so với `original_price`. Xóa an toàn.
- **`stock_item_qty`, `stock_item_min_sale_qty`, `stock_item_max_sale_qty`**: hằng số ở toàn bộ giá trị không rỗng (1000, 1, 1000), và 8 dòng rỗng còn lại khớp chính xác 100% với cờ `possibly_delisted` đã có sẵn → không mang thêm thông tin. Xóa cả 3.
- **`seller_price`**: khớp tuyệt đối với `price` ở toàn bộ dòng có dữ liệu; phần rỗng cũng khớp 100% với `possibly_delisted`. Xóa an toàn.
- **`seller_is_best_store`**: hằng số False ở toàn bộ dòng có dữ liệu; phần rỗng khớp 100% với `possibly_delisted`. Xóa an toàn.

Giữ lại dù ban đầu nghi ngờ dư thừa (kèm lý do):

- **`quantity_sold_value` và `quantity_sold_value_filled`**: phục vụ 2 mục đích khác nhau — cột gốc giữ đúng phân biệt "chưa bán" khi lọc theo `has_sold`, cột `filled` tiện cho tổng hợp (`groupby().sum()`).
- **`inventory_status`, `inventory_type`**: có biến thiên thật, không phải hằng số (`inventory_status`: 1993 available / 7 out_of_stock / 1 upcoming; `inventory_type`: 1556 backorder / 444 instock / 1 discontinued) — đáng chú ý là **77.8% sản phẩm ở trạng thái backorder**, một tín hiệu có giá trị phân tích riêng.
- **`discount_rate_mismatch`**: xem mục 5 — đang hoạt động đúng, phát hiện 2 bất thường thật.

10. Lưu dữ liệu đã làm sạch

- Xuất `products_cleaned.csv` và `reviews_cleaned.csv` vào `02_data/processed/`.

11. Báo cáo tổng kết

- Tự động sinh `cleaning_report.md`: số dòng trước/sau, danh sách cột đã xóa, số bản ghi được gắn cờ (`possibly_delisted`, `discount_rate_mismatch`, `review_mismatch...`) để phục vụ theo dõi và xem xét thủ công.