

Data Collection - Crawl dữ liệu từ Tiki

1. Cách làm

Sử dụng thư viện request và json trong Python:

- **Bước 1:** Crawl product_id của tất cả sản phẩm trong danh mục “**Đồ dùng nhà bếp**” (tối đa khoảng 2000 sản phẩm), sau đó xử lý và lưu thành file csv.
- **Bước 2:** Từ file csv chứa các product_id ở bước trên, đọc lại file đó và crawl tiếp sản phẩm (product) từ các product_id, sau đó trích xuất API, rồi lưu thành file csv chứa các thông tin liên quan như: tên sản phẩm, giá niêm yết, giá sau khi được giảm,...
- **Bước 3:** Cũng từ file csv chứa các product_id đó, đọc lại và tiếp theo là crawl đánh giá (comment) của các sản phẩm từ product_id đó, sau đó trích xuất API và lưu thành file csv.

2. Cấu trúc thư mục

Gồm 2 folder:

a. Folder [data_collection](#): chứa các file crawl dữ liệu

i. file [crawl_product_ids.py](#)

- Sử dụng Python và thư viện Requests để gọi Tiki Listing API của danh mục Đồ dùng nhà bếp.

```
data_collection > 🐍 crawl_product_ids.py > ...
1  import os
2  import time
3  import random
4  import pandas as pd
5  import requests
6  from dotenv import load_dotenv
7
8
9  load_dotenv()
10
11
12  BASE_URL = "https://tiki.vn/api/personalish/v1/blocks/listings"
13  CATEGORY_ID = 1884
14  CATEGORY_URL_KEY = "do-dung-nha-bep"
15  LIMIT = 40
```

- API được phân trang với giới hạn 40 sản phẩm mỗi request. Ở mỗi trang, hệ thống trích xuất product_id và sử dụng set để loại bỏ các ID trùng lặp.
- Quá trình crawling dừng khi API không trả về sản phẩm hoặc trang tiếp theo không tạo ra product_id mới.

```
while True:
    params["page"] = page
    print(f"Requesting page {page}...")
    try:
        response = session.get(
            BASE_URL,
            headers=headers,
            params=params,
            timeout=30,
        )
        response.raise_for_status()
    except requests.RequestException as e:
        print(f"Request failed on page {page}: {e}")
        break

    try:
        response_data = response.json()
    except ValueError:
        print(f"Invalid JSON response on page {page}")
        break

    data = response_data.get("data", [])

    if not data:
        print(f"No products found on page {page}. Stopping.")
        break
```

```
previous_count = len(product_ids)
for record in data:
    product_id = record.get("id")
    if product_id is not None:
        product_ids.add(product_id)

new_count = len(product_ids) - previous_count
print(
    f"Page {page}: "
    f"{len(data)} records, "
    f"{new_count} new product IDs, "
    f"{len(product_ids)} total unique IDs"
)

# Nếu page không tạo ra product ID mới, pagination đã kết thúc.
if new_count == 0:
    print("No new product IDs. Stopping.")
    break

page += 1
```

- Giữa các request, hệ thống áp dụng thời gian chờ ngẫu nhiên 3–7 giây nhằm hạn chế gửi request liên tục. Kết quả cuối cùng được lưu dưới dạng file `product_ids.csv`.

```
# Random delay giữa các requests
delay = random.uniform(3, 7)
time.sleep(delay)

# Save result

df = pd.DataFrame(
    {
        "product_id": sorted(product_ids)
    }
)

output_file = "product_ids.csv"

df.to_csv(
    output_file,
    index=False,
    encoding="utf-8-sig",
)
```

ii. File [crawl_product_data.py](#)

- Sử dụng danh sách `product_id` đã thu thập để gọi Tiki Product API và lấy thông tin chi tiết của từng sản phẩm.

```
# Configuration

INPUT_FILE = "product_ids.csv"
OUTPUT_FILE = "crawled_product_data.csv"
BASE_URL = "https://tiki.vn/api/v2/products"
TIKI_ACCESS_TOKEN = os.getenv("TIKI_ACCESS_TOKEN")
TIKI_TRACKITY_ID = os.getenv("TIKI_TRACKITY_ID")
```

- Dữ liệu được trích xuất thành các nhóm thuộc tính gồm thông tin sản phẩm, giá và giảm giá, đánh giá và doanh số, tồn kho, thương hiệu, nhà bán hàng và danh mục.

```
# Parser
def parser_product(product):
    brand = product.get("brand") or {}
    current_seller = product.get("current_seller") or {}
    categories = product.get("categories") or {}
    quantity_sold = product.get("quantity_sold") or {}
    stock_item = product.get("stock_item") or {}
    return {
        "id": product.get("id"),
        "sku": product.get("sku"),
        "product_name": product.get("name"),
        "meta_title": product.get("meta_title"),
        "short_description": product.get("short_description"),

        # ---- Pricing ----
        "price": product.get("price"),
        "list_price": product.get("list_price"),
        "original_price": product.get("original_price"),
        "discount": product.get("discount"),
        "discount_rate": product.get("discount_rate"),

        # ---- Rating & Sales ----
        "rating_average": product.get("rating_average"),
        "review_count": product.get("review_count"),
        "quantity_sold_text": quantity_sold.get("text"),
```

- Hệ thống sử dụng requests.Session() để quản lý các request, kết hợp cơ chế retry tối đa 3 lần cho các lỗi tạm thời như 429 và 5xx. Giữa các request áp dụng khoảng nghỉ ngẫu nhiên 2–4 giây.

```
with requests.Session() as session:
    session.headers.update(headers)
    for pid in tqdm(p_ids):
        url = f"{BASE_URL}/{pid}"
        success = False
        for attempt in range(3):
            try:
                response = session.get(url,
                    params={
                        "platform": "web"
                    },
                    timeout=30,
                )
                if response.status_code == 200:
                    product = response.json()
                    result.append(parser_product(product))
                    success = True
                    break
            elif response.status_code in {429, 500, 502, 503, 504, }:
                time.sleep(
                    5 * (attempt + 1)
                )
```

- Các sản phẩm thu thập thành công được lưu vào crawled_product_data.csv.

iii. File [crawl_comments.py](#)

- Sử dụng các `product_id` và `review_count` từ dữ liệu sản phẩm để gọi Tiki Review API. Chỉ những sản phẩm có `review_count > 0` mới được crawl.
- Review được thu thập theo từng trang với 5 review mỗi request và quá trình phân trang dừng khi API không còn dữ liệu, đạt trang cuối hoặc trả về số review ít hơn giới hạn mỗi trang.
- Hệ thống có cơ chế retry tối đa 3 lần đối với các lỗi tạm thời như 429 và 5xx, đồng thời áp dụng delay ngẫu nhiên 2–5 giây giữa các request.
- Thông tin review gồm nội dung, rating, thời gian, số lượt cảm ơn và thông tin khách hàng; tên khách hàng được **ẩn danh bằng SHA-256 hash** trước khi lưu trữ.
- Dữ liệu được lưu định kỳ và cuối cùng xuất ra `comments_data.csv`, trong khi các sản phẩm crawl thất bại được ghi vào `failed_comment_product_ids.csv`.
 - b. **Folder data**: chứa các folder raw (chứa các file thô csv được crawl) và folder processed (chứa các file csv đã được làm sạch)